山东大学
SHANDONG UNIVERSITY

实验报告

课　　程：	Data Mining
实验题目：	Homework 1
姓　　名：	陈昕
学　　号：	201814806
班　　级：	2018 级计算机学硕班
实验时间：	2018/10/8 – 2018/11/5

一、 实验目的

用 git 创建项目并上传到 GitHub 上，并学会使用 git 的基本命令。

理解课堂上学到的 Vector space model 和 KNN 分类方法，并在 20 Newsgroups 数据集上实践课堂上学到的文本处理、tf-idf、cosine similarity、反向索引及 KNN 分类等知识。

任务：

1. 预处理文本数据集，并且得到每个文本的 VSM 表示。
2. 实现 KNN 分类器，测试其在 20Newsgroups 上的效果。

二、 实验环境

硬件环境：

intel i5-7400 CPU @ 3.00 GHz
8.00 GB RAM

软件环境：

Windows 10 64 位 家庭版
python 3.6.6
Anaconda custom (64-bit)
Jupyter notebook 5.7.0
nltk 3.3.0

三、 实验过程

（我不能保证在报告描述中变量名与实际程序中完全一致。）

准备工作

从 https://git-scm.com/downloads 上可以下载到最新的 git 发行版。

在 GitHub 上创建账号，然后按 start a project 创建项目。

整个实验主程序的入口是 main.ipynb，可以通过 jupyter notebook 运行。

在任务正式开始之前，先从 http://qwone.com/~jason/20Newsgroups/ 上下载了 20news-18828.tar.gz 数据集，并用 7zip 将其解压。

任务一：预处理文本数据集，并且得到每个文本的 VSM 表示。

我在这个任务中使用 nltk(Natural Language Toolkit)来进行文本的预处理，将文本转化为词语集合，并自己编写了一个类 VectorSpaceModel 来把词语集合转换为 VSM 表示。

根据面向对象的单一职责原则，VectorSpaceModel 类没有文本预处理功能，文本预处理过程在 main.ipynb 中进行。

在 main.ipynb 中的文本预处理和转化为 VSM 的过程如下：

首先，用 os 模块获取 20Newsgroups 数据集的所有文件路径，filepaths。

将 filepaths 分为训练集 training_set_fns 和测试集 test_set_fns（fn 是 file name 的缩写）。

然后，用文件读取函数 open()打开 training_set_fns 中的所有文档。**文档的编码方式为 latin1。**

Nltk 包中提供了 stopwords，tokenizer 和 stemmer。先用 RegexpTokenizer 从文档中取出所有单词，然后把所有词转换为小写并用 stemmer 取词干，最后过滤掉所有属于 stopwords 的停词。

对测试集中的所有文档进行上述处理，得到一个分词后的文件列表，命名为 tokenized_docs。这样就结束了文本预处理过程。

VSM 表示的各种功能是在 VectorSpaceModel 类里实现的。

在 main.ipynb 里，遍历 tokenized_docs，对每个文档用 VectorSpaceModel 包装，并将其中的词语加入计算 DF，并在遍历结束后计算 IDF。完成后即可计算各个 VSM 里每个词的 tf-idf 权重，再把向量转为单位向量。

我实现了 sub-linear 和 maximum 两种 tf normalization 方法，还可以选择直接使用 tf。这些选择定义在一个枚举类 TF_Scale 中。

在 main.ipynb 中，我选择了使用 maximum 方法来 normalize 词频。

VectorSpaceModel.py 文件中：

包括两个类 TF_Scale 和 VectorSpaceModel。

枚举类 TF_Scale 里定义了 TF 的 3 种 normalization 方式：RAW 代表不 normalization，SUB_LINEAR 表示使用$tf(t,d) = \begin{cases} 1+\log c(t,d), \ if\ c(t,d)>0 \\ 0, \ otherwise \end{cases}$，MAXIMUM 表示使用$tf(t,d) = \alpha + (1-\alpha)\frac{c(t,d)}{\max\limits_{t} c(t,d)}$。

类 VectorSpaceModel 的类属性包括：

- **rawDF**（整个词典和文档频率的字典）
- **_IDF**（值为 IDF 值的字典）
- **alpha**（进行 Maximum TF scaling 时的α）

对象属性包括：

- **rawTF**（基于内置 Counter 的词频统计字典）
- **_maxCountInTF**（进行 Maximum TF scaling 时的最高词频）
- **vector**（存放存在于文档中的词以及它们的权重）。

类 VectorSpaceModel 的方法都比较简单，包括：

- calTF(根据 TF_Scale 所指定的方法计算 tf)
- calIDF（计算 IDF）
- accumulateDocumentFrequency（添加新文档信息到 rawDF）
- calWeight（计算 vector）
- normalize（把向量单位化）
- getTerms（返回文档中包含的所有词）
- getCorpus（返回全局的所有词语）
- dot 和 dotProduct（用两个标准化后的 VSM 进行点乘）。

我没有选择使用矩阵来记录各 VSM 表示，因为一个文档基本不可能拥有语料库中的所有词，用矩阵表示有极大可能得到稀疏的矩阵，不必要的 0 会占用过多的内存空间。

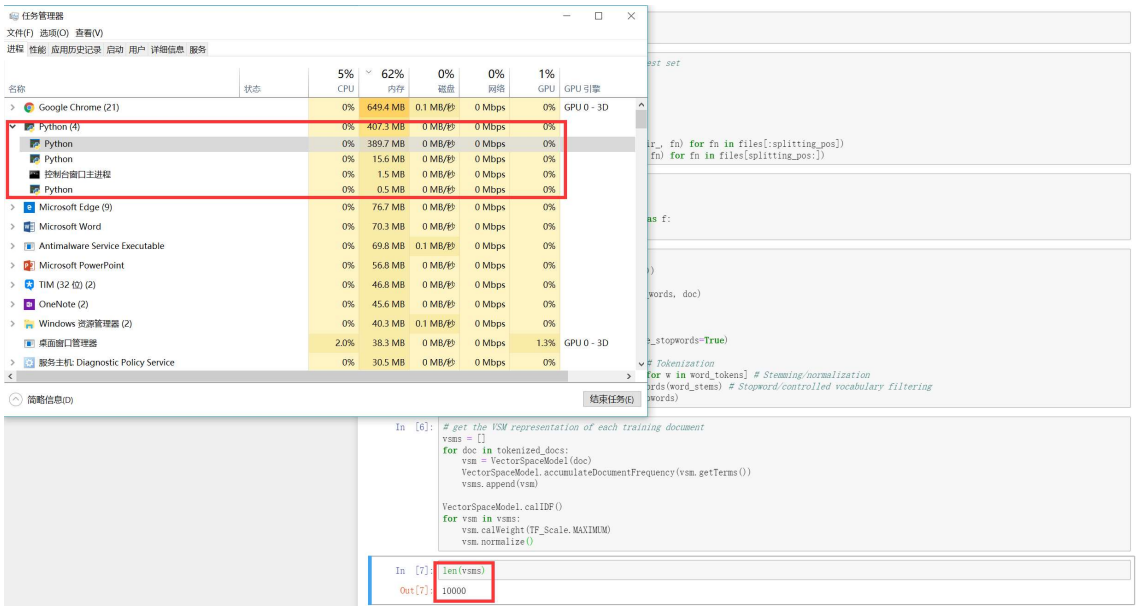

如图所示，在用 VectorSpaceModel 的对象列表来替代矩阵的情况下，尽管列表里包含 10000 个文档且仅使用 stopwords 过滤，内存消耗也只需要约 400MB，不会撑爆 8G 内存。

而用字典进行向量单位化和点乘也是节省时间与内存的，因为如果一个词的词频为 0，那么它不会影响这两个过程的结果，反而会花费不必要的时间。

任务二：实现 KNN 分类器，测试其在 20Newsgroups 上的效果。

我的 KNN 分类器实现在 KNNClassifier.py 中，测试代码依旧写在 main.ipynb 中。

在 main.ipynb 中的进行的分类过程如下：

首先，从测试集 test_set_fns 中随机选择 200 个文件，读取并转化为 VSM 表示。

接着构建 KNN 分类器。训练集的标签 labels 来自它们的文件夹名，可通过 os.path.dirname 得到。用训练集数据和 labels 就可以构建 KNNClassifier，而 train 函数中构建了反向索引。

然后，以 1-100 这 100 个 k 作为参数，用分类器对测试集进行分类。

在分类完成后，对比分类器生成的 label 和测试集的实际 label（也就是文件夹名），计算错误率。

通过 numpy 包的方法，找到最佳 k 值，并用 matplotlib 画出错误率曲线，如下图所示：

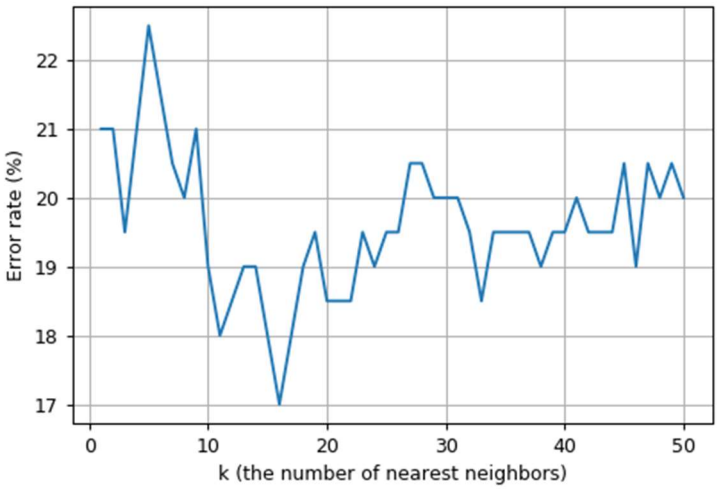

结果显示在 k=16 时错误率最小，约 17%。之后虽然有些，但趋势是向上的，也就是说 k 并不是越大越好。

我还打印了所有被选中的测试集的文件名，作为参考。

最后，我用 k=16 对全部测试集进行了分类，结果显示错误率约为 20.2%。

KNNClassifier.py 文件中：

该文件只包括 KNNClassifier 一个类。

类 KNNClassifier 中，没有类属性。

对象属性包括：

- **vsms**（训练数据集的 vsm 列表）
- **labels**（每个数据对应的标签）
- **invertedList**（作为反向索引的字典）。

对象方法包括：

- **buildInvertedList**（构建反向索引）
- **train**（内部调用 buildInvertedList 方法）
- **classify**（使用 inverted list 和 heap 来加速找到 k 近邻，用 Counter 求出 k 近邻中最多的 label,作为分类结果）

train 方法的存在是为了我想象中的 Classifier 接口，它应该有 train 和 classify 两个方法，所有 client 都应该只需要调用这两个方法，减小调用方的成本。

classify 方法是分类的主方法，要被调用多次，所以我使用反向索引和 heapq 模块提供的 nlargest 方法来进行加速。

四、 实验结论

在本次实验中，我动手实现了课堂上学到的文本预处理、vector space model 构建和 KNN 分类，感觉对这些知识点的理解更深入了。

在读取文件时，我发现 utf8 有些无法解析的字符，在网上查找后发现换用 latin1 编码就能解析全部文件了。这是因为基本上各种编码都兼容 ASCII 字符，而各种文本编辑器优先把只包含 ASCII 字符的文件是 utf8 编码的，但这样在碰到 latin1 字符时就会出现解析错误。

我还发现了 nltk 这个强大的自然语言处理工具，用它进行了分词、取词干、过滤停词的操作。它还有词性标记、解析、获取语义等功能，但我在本次实验中没有用到。

在实现 vector space model 时，我实现了 sub-linear 和 maximum 两种 tf normalization 方式，并用 dict 作为 vector，且实现了 vector 点乘。

在进行 knn 分类时，由于把所有训练集全部计算一遍太慢了，我就用了 random 模块的方法，每次随机挑 200 个。最后一次的结果最佳 k 值为 16，正确率约 80%，之前几次最佳 k 值也在 10-30 之间，可以猜测在这个区间取 k 对整个数据集效果最好。